```
In [1]:
        import re
        import pandas as pd
        from io import open
        import numpy as np
In [2]:
        fichero = open ( "Web access log-akumenius.com.txt", "r")
        lineas= fichero.readlines()
        for i in range (15, 30):
            print (lineas[i])
        fichero.close()
        localhost 127.0.0.1 - - [23/Feb/2014:03:10:31 +0100] "OPTIONS * HTTP/1.0" 200 - "-" "Apach
        e (internal dummy connection)" VLOG=-
        localhost 127.0.0.1 - - [23/Feb/2014:03:10:31 +0100] "OPTIONS * HTTP/1.0" 200 - "-" "Apach
        e (internal dummy connection) " VLOG=-
        localhost 127.0.0.1 - - [23/Feb/2014:03:10:31 +0100] "OPTIONS * HTTP/1.0" 200 - "-" "Apach
        e (internal dummy connection)" VLOG=-
        localhost 127.0.0.1 - - [23/Feb/2014:03:10:31 +0100] "OPTIONS * HTTP/1.0" 200 - "-" "Apach
        e (internal dummy connection) " VLOG=-
        localhost 127.0.0.1 - - [23/Feb/2014:03:10:31 +0100] "OPTIONS * HTTP/1.0" 200 - "-" "Apach
        e (internal dummy connection)" VLOG=-
        localhost 127.0.0.1 - - [23/Feb/2014:03:10:31 +0100] "OPTIONS * HTTP/1.0" 200 - "-" "Apach
        e (internal dummy connection) " VLOG=-
        localhost 127.0.0.1 - - [23/Feb/2014:03:10:31 +0100] "OPTIONS * HTTP/1.0" 200 - "-" "Apach
        e (internal dummy connection) " VLOG=-
        www.akumenius.com 66.249.76.216 - - [23/Feb/2014:03:10:31 +0100] "GET /hoteles-baratos/ofe
        rtas-hotel-Club-&-Hotel-Letoonia--en-Fethiye-8460b-destinos.html HTTP/1.1" 404 3100 "-" "M
        ozilla/5.0 (compatible; Googlebot/2.1; +http://www.google.com/bot.html) " VLOG=-
        www.akumenius.com 66.249.76.216 - - [23/Feb/2014:03:10:33 +0100] "GET /hoteles-baratos/ofe
        rtas-hotel-Metropolis-Hotel-en-Kaunas-210244b-destinos.html HTTP/1.1" 404 3100 "-" "Mozill
        a/5.0 (compatible; Googlebot/2.1; +http://www.google.com/bot.html) " VLOG=-
        www.akumenius.com 66.249.76.216 - - [23/Feb/2014:03:10:35 +0100] "GET /hoteles-baratos/ofe
        rtas-hotel-Faena-Hotel-Buenos-Aires-en-Downtown-129723b-destinos.html HTTP/1.1" 404 3100
        "-" "Mozilla/5.0 (compatible; Googlebot/2.1; +http://www.google.com/bot.html)" VLOG=-
        www.akumenius.com 66.249.76.216 - - [23/Feb/2014:03:10:38 +0100] "GET /hoteles-baratos/ofe
        rtas-hotel-Kensington-Townhouse-London-en-Kensington-54356b-destinos.html HTTP/1.1" 404 31
        00 "-" "Mozilla/5.0 (compatible; Googlebot/2.1; +http://www.google.com/bot.html)" VLOG=-
        www.akumenius.com 66.249.76.216 - - [23/Feb/2014:03:10:39 +0100] "GET /destinos-baratos/de
        stinosEstrelles/hoteles-en-Invermere CANAD%C3%81-con-4-estrellas HTTP/1.1" 200 8811 "-" "M
        ozilla/5.0 (compatible; Googlebot/2.1; +http://www.google.com/bot.html) " VLOG=-
        www.akumenius.com 66.249.76.216 - - [23/Feb/2014:03:10:40 +0100] "GET /hoteles-baratos/ofe
        rtas-hotel-Howard-Jhonson-hotel-&-Spa--Villa-Gral-Belgrano-en-Villa%20General%20Belgrano-1
        46416b-destinos.html HTTP/1.1" 404 3100 "-" "Mozilla/5.0 (compatible; Googlebot/2.1; +htt
        p://www.google.com/bot.html) " VLOG=-
```

www.akumenius.com 66.249.76.216 - - [23/Feb/2014:03:10:42 +0100] "GET /hoteles-baratos/ofe rtas-hotel-Princesa-Sofia-en-Diagonal%20S.-4013b-destinos.html HTTP/1.1" 404 3100 "-" "Moz

illa/5.0 (compatible; Googlebot/2.1; +http://www.google.com/bot.html) " VLOG=-

www.akumenius.com 66.249.76.216 - - [23/Feb/2014:03:10:45 +0100] "GET /hoteles-baratos/ofe
rtas-hotel-Kfar-Giladi-en-Tiberias-121085b-destinos.html HTTP/1.1" 404 3100 "-" "Mozilla/
5.0 (compatible; Googlebot/2.1; +http://www.google.com/bot.html)" VLOG=-

```
In [5]: print (len(lineas)) # miramos la longitud(líneas) del archivo.
```

261873

Mirando el archivo de manera aleatoria, y en diferentes sitios, podemos diferenciar dos tipos diferentes de líneas.

Una, en que el acceso es desde el *servidor local*. Otra en que es conexión a la web es por transmisión de datos via *www*.

- Rápidamente observamos tres variables: una manera de acceder a la web mediante www o localhost, una IP y la fecha. Vemos que la manera en que están posicionados en las filas es igual en ambos tipos de filas. El acceso a la web o Localhost está separados de la ip mediante un espacio en blanco mientras que la IP y la fecha están separadas de por dos guiones y tres espacios en blanco de la siguiente forma " - ". Por lo que identificamos 3 variables: Acceso, IP y fecha de acceso
- Tras la variable tiempo observamos dos variables contenidad en entre dos pares comillas. "......". Vemos que en los registros de servidor local, tenemos dos variables. Una que pone *OPTIONS*, y la versión del *protocolo HTTP*, mientras que en las líneas que acceden via www, tenemos el resultado obtenido de lo que aparenta una *búsqueda* y el *protocolo HTTP*.
- *Uno o dos números*: después del protocolo HTTP, tenemos un número de 3 cifras seguidos de un guión en el caso de localhost, y de 7 o más cifras en el WWW. Pero separados por un espacio de la forma xxx yyyy
- Nota. Hasta éste punto las separaciones de datos han sido coherentes. Es decir, hemos encontrado información separada por espacios, o por guiones, en ambos sitios, y las supuestas variables separadas por algún caracter especial o espacion en blanco, tienen su cierta coherencia. En éste punto es el único que las cosas no coinciden. I
- Tras esto tenemos un valor entre comillas, que tal vez es el más dificil de ver, ya que hay pocos registros con datos, como muestro más abajo. Podemos ver "http://www.akumenius.com/" o nada. La llamaremos variable X. Sí algo hay en común son las comillas. Por último, vemos otro registro, entre comillas que es el navegador con el que se ha accedido.
- Bien, menos por la variable de los números(que no sabemos como opera), y la variable X, el resto parecen fácilmente identificables. A pesar de ello, sí he podido identificar unos patrones de separación de información, de los que me aprovecharé para dejar las líneas preparadas para convertir en Dataframe, reconvertiendo todas estos carácteres comunes en ";"

```
for i in range(224574,224579):
    print (lineas[i])
# y podemos ver que hay un registro de una web. También vemos que en el navegador, da más
```

www.akumenius.com 37.11.115.207 - - [28/Feb/2014:00:48:12 +0100] "GET /includes/images/upl oaded/Slideshow/ESC-RELAX-LANJARON.png HTTP/1.1" 200 42972 "http://www.akumenius.com/" "Mo zilla/5.0 (Windows NT 6.0) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/31.0.1650.63 Safa ri/537.36" VLOG=-

www.akumenius.com 37.11.115.207 - - [28/Feb/2014:00:48:12 +0100] "GET /modules/raton/view s/themes/bcoos/images/buscadores/icono-facebook.png HTTP/1.1" 200 2167 "http://www.akumeni

us.com/" "Mozilla/5.0 (Windows NT 6.0) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/31.0. 1650.63 Safari/537.36" VLOG=www.akumenius.com 37.11.115.207 - - [28/Feb/2014:00:48:12 +0100] "GET /modules/raton/view s/themes/bcoos/images/cercle blau.png HTTP/1.1" 200 3770 "http://www.akumenius.com/" "Mozi lla/5.0 (Windows NT 6.0) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/31.0.1650.63 Safar i/537.36" VLOG=www.akumenius.com 37.11.115.207 - - [28/Feb/2014:00:48:12 +0100] "GET /includes/images/upl oaded/Promociones/p benidorm.jpg HTTP/1.1" 200 14646 "http://www.akumenius.com/" "Mozilla/ 5.0 (Windows NT 6.0) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/31.0.1650.63 Safari/53 7.36" VLOG=www.akumenius.com 37.11.115.207 - - [28/Feb/2014:00:48:12 +0100] "GET /includes/images/upl oaded/Promociones/p granada.jpg HTTP/1.1" 200 18269 "http://www.akumenius.com/" "Mozilla/ 5.0 (Windows NT 6.0) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/31.0.1650.63 Safari/53 7.36" VLOG=-In [20]: linearr= np.array (lineas) # convertimos la lista en una array para más adelante vectoriza In [22]: # cómo queremos separar todas las referencias por ";", vamos a eliminar todos los puntos j # documento, sustituyendo "; " por "," def puntocoma(x): x= re.sub("; ", ", ", x) return x coma =np. vectorize (puntocoma) linearr= coma(linearr) print (linearr[113]) # tengo la línea 113 localizada con puntos y comas. www.akumenius.com 66.249.76.216 - - [23/Feb/2014:03:12:49 +0100] "GET /hoteles-baratos/ofe rtas-hotel-The-Sukosol-en-Rajatevee-%20Phayathai-60694b-destinos.html HTTP/1.1" 404 3100 "-" "Mozilla/5.0 (compatible, Googlebot/2.1, +http://www.google.com/bot.html)" VLOG=-In [8]: prueba1 = linearr[11234].copy() # usaremos esta línea como campo de pruebas para luego aplicar sobre todo el bloque In [23]: # primero, substituímos los dos primeros espacios en blanco en una ";", de forma que quede pruebal1= re.sub("\s", ";", pruebal, 2) print (prueball) www.akumenius.com;81.45.52.213;- - [23/Feb/2014:11:02:43 +0100] "POST /destinos-get HTTP/ 1.1" 200 26 "http://www.akumenius.com/" "Mozilla/5.0 (Linux; U; Android 4.1.1; es-es; GT-I 8190 Build/JR003H) AppleWebKit/534.30 (KHTML, like Gecko) Version/4.0 Mobile Safari/534.3 0" VLOG=-In [24]: # luego vamos a eliminar los dos primeros espacios en blanco que queden así como los dos prueba12= re.sub("-", "", prueba11,2) prueba12=re.sub("\s","", prueba12,2) print(prueba12) # de esta manera nos quedan perfectamente separadas 3 variables por ";" www.akumenius.com;81.45.52.213;[23/Feb/2014:11:02:43 +0100] "POST /destinos-get HTTP/1.1" 200 26 "http://www.akumenius.com/" "Mozilla/5.0 (Linux; U; Android 4.1.1; es-es; GT-I8190

Build/JR003H) AppleWebKit/534.30 (KHTML, like Gecko) Version/4.0 Mobile Safari/534.30" VLO

```
In [25]:

# si observamos las siguientes 4 comillas, vemos que casualmente nos separan la variable
# así como el número de la variable X, y esta última del navegador.
prueba13= re.sub('"', ";", prueba12,4)
prueba13= re.sub('"', "", prueba13,1) # luego eliminamos la siguiente comilla porque convei
# más completámente vacían
prueba13= re.sub('"', ";", prueba13,1)
print(prueba13)
```

www.akumenius.com;81.45.52.213;[23/Feb/2014:11:02:43 +0100] ;POST /destinos-get HTTP/1.1;
200 26 ;http://www.akumenius.com/; Mozilla/5.0 (Linux; U; Android 4.1.1; es-es; GT-I8190 B
uild/JR003H) AppleWebKit/534.30 (KHTML, like Gecko) Version/4.0 Mobile Safari/534.30; VLOG
=-

www.akumenius.com;92.56.114.50;[23/Feb/2014:15:58:04 +0100] ;GET /libraries/anythingSlide r/images/4a.png HTTP/1.1; 200 2410 ;http://www.akumenius.com/; Mozilla/5.0 (Linux, U, Android 4.0.4, es-es, SonyEricssonLT22i-o Build/6.1.1.B.1.54) AppleWebKit/534.30 (KHTML, like Gecko) Version/4.0 Mobile Safari/534.30; VLOG=-

```
fichero = open ( "weblog.csv", "w")
fichero.write("Web;IP;Fecha;Busqueda;Numero;origen;Navegador;VLOG\n")
for i in range (0, len(linearr)):
    fichero.write(linearr[i])
fichero.close()
```

```
In [45]: # creamos el DF
    df= pd.read_csv("weblog.csv", sep=";")
    df
```

Out[45]:		Web	IP	Fecha	Busqueda	Numero	origen	Navegador	VL
	0	localhost	127.0.0.1	[23/Feb/2014:03:10:31 +0100]	OPTIONS * HTTP/1.0	200 -	-	Apache (internal dummy connection)	VLOG
	1	localhost	127.0.0.1	[23/Feb/2014:03:10:31 +0100]	OPTIONS * HTTP/1.0	200 -	-	Apache (internal dummy connection)	VLOG
	2	localhost	127.0.0.1	[23/Feb/2014:03:10:31 +0100]	OPTIONS * HTTP/1.0	200 -	-	Apache (internal dummy connection)	VLOG

	Web	IP	Fecha	Busqueda	Numero	origen	Navegador	VL
3	localhost	127.0.0.1	[23/Feb/2014:03:10:31	OPTIONS *	200 -	_	Apache (internal dummy	VLOG
			+0100]	HTTP/1.0			connection)	
4	localhost	127.0.0.1	[23/Feb/2014:03:10:31	OPTIONS	200 -		Apache (internal dummy	VLOG
7	localilost	127.0.0.1	+0100]	HTTP/1.0	200		connection)	VLOC
•••								
261868	www.akumenius.com	5.255.253.53	[02/Mar/2014:03:05:39 +0100]	GET / HTTP/1.1	200 7528	-	Mozilla/5.0 (compatible, YandexBot/3.0, +http	VLOG
261869	www.akumenius.com	74.86.158.107	[02/Mar/2014:03:09:52 +0100]	HEAD / HTTP/1.1	200 -	-	Mozilla/5.0+ (compatible, UptimeRobot/2.0, htt	VLOG
261870	localhost	127.0.0.1	[02/Mar/2014:03:10:18	OPTIONS *	200 -	_	Apache (internal dummy	VLOG
			+0100]	HTTP/1.0			connection)	
261871	localhost	127.0.0.1	[02/Mar/2014:03:10:18	OPTIONS	200 -		Apache (internal dummy	VLOG
201071	localilost	127.0.0.1	+0100]	HTTP/1.0	200 -		connection)	VLOC
261072	lo calla oct	127.0.0.1	[02/Mar/2014:03:10:18	OPTIONS	200		Apache (internal	\/I.OC
261872	localhost	127.0.0.1	+0100]	HTTP/1.0	200 -	-	dummy connection)	VLOC
261873 r	ows × 8 columns							

In [50]: df.iloc[223334:223345]

Numer	Busqueda	Fecha	IP	Web		Out[50]:
20 1509	POST /hotel-list-data HTTP/1.1	[28/Feb/2014:00:05:12 +0100]	88.12.69.210	www.akumenius.com	223334	
20 963	GET /hotel-list HTTP/1.1	[28/Feb/2014:00:05:13 +0100]	88.12.69.210	www.akumenius.com	223335	
20 1131	GET /modules/raton/views/themes/bcoos/css/2col	[28/Feb/2014:00:05:13 +0100]	88.12.69.210	www.akumenius.com	223336	
20 722	GET /libraries/jqueryui/js/jquery.ui.button.mi	[28/Feb/2014:00:05:14 +0100]	88.12.69.210	www.akumenius.com	223337	

		Web	IP	Fecha	Busqueda	Numer		
	223338	www.akumenius.com	88.12.69.210	[28/Feb/2014:00:05:14 +0100]	GET /libraries/jqueryui/css/ui-lightness/jquer	20 247		
	223339	www.akumenius.com	88.12.69.210	[28/Feb/2014:00:05:14 +0100]	GET /libraries/jqueryui/js/jquery.ui.draggable	20 1884		
	223340	www.akumenius.com	88.12.69.210	[28/Feb/2014:00:05:14 +0100]	GET /libraries/jqueryui/js/jquery.ui.dialog.mi	20 1169		
	223341	www.akumenius.com	88.12.69.210	[28/Feb/2014:00:05:15 +0100]	GET /libraries/jqueryui/css/ui-lightness/jquer	20 135		
	223342	www.akumenius.com	88.12.69.210	[28/Feb/2014:00:05:15 +0100]	GET /modules/raton/views/themes/bcoos/css/butt	200 4		
	223343	www.akumenius.com	88.12.69.210	[28/Feb/2014:00:05:15 +0100]	GET /modules/raton/views/themes/bcoos/googleMa	20 708		
	223344	www.akumenius.com	88.12.69.210	[28/Feb/2014:00:05:16 +0100]	GET /libraries/jqueryui/js/jquery.ui.slider.mi	20 1010		
In [57]:	[57]: # por último vamos a separa la columna búsqueda en 3. # podemos ver que hay tres variables. Una que manda un comando de acción que se difere # que alguna opción más. La segunda variable suele ser una búsqueda y por último el pr # separados por espacios. Así que usaremos split para separar y crear nuevas columnas							
		sert(9,"busqueda'			<pre>k: k.split(" ")[0])) da k: k.split(" ")[1] if len(k.split</pre>	t(" "))		

Out[57]:	Web		IP	IP Fecha		Numero	origen	Navegador	VL
	261868	www.akumenius.com	5.255.253.53	[02/Mar/2014:03:05:39 +0100]	GET / HTTP/1.1	200 7528	-	Mozilla/5.0 (compatible, YandexBot/3.0, +http	VLO6
	261869	www.akumenius.com	74.86.158.107	[02/Mar/2014:03:09:52 +0100]	HEAD / HTTP/1.1	200 -	-	Mozilla/5.0+ (compatible, UptimeRobot/2.0, htt	VLOG

		Web) IP	Fecha	Busqueda Numero	origen	Nave	gador	VL
	261870) localhost	127.0.0.1	[02/Mar/2014:03:10:18 +0100]	OPTIONS * 200 - HTTP/1.0	-			VLOG
	261871	1 localhost	t 127.0.0.1	[02/Mar/2014:03:10:18 +0100]	OPTIONS * 200 - HTTP/1.0	-		nternal lummy ection)	VLOG
	261872	2 localhost	t 127.0.0.1	[02/Mar/2014:03:10:18 +0100]	OPTIONS * 200 - HTTP/1.0	-			VLOG
In [58]:	df.i]	loc[23334:23345]							
Out[58]:		Web	IP	Fecha	В	usqueda	Numero	origen	
	23334	www.akumenius.com	66.249.76.216	[23/Feb/2014:16:16:59 +0100]	/destinosCaracteristicas/ ba	GET /hoteles- ratos-e	200 16600	-	Gc
	23335	www.akumenius.com	5.10.83.52	[23/Feb/2014:16:16:59 +0100]	GET /destinosEstrelles/ en-%20(G		200 8800	-	. А
	23336	www.akumenius.com	66.249.76.216	[23/Feb/2014:16:17:00 +0100]	GET /c baratos/destinosEstrelles,	destinos- /hotele	200 8858	-	Gc
	23337	www.akumenius.com	180.76.5.28	[23/Feb/2014:16:17:03 +0100]	GET /destinos-baratos/c caracte	destinos- eristicas	200 7196	-	Baic
	23338	www.akumenius.com	66.249.76.216	[23/Feb/2014:16:17:03 +0100]	GET /c caracteristicas/hoteles-b	destinos- paratos	200 8260	-	Gc
	23339	www.akumenius.com	66.249.76.216	[23/Feb/2014:16:17:08 +0100]	GET /c caracteristicas/hoteles-b	destinos- paratos	200 9534	-	Gc
	23340	www.akumenius.com	180.76.5.97	[23/Feb/2014:16:17:09 +0100]	GET /destinos-baratos/c	destinos- eristicas	200 8526	-	Baic

[23/Feb/2014:16:17:12

[23/Feb/2014:16:17:16

23341 www.akumenius.com 66.249.76.216

23342 www.akumenius.com 66.249.76.216

200

200

8831

14719

caracteristicas...

GET /destinos-

GET /destinos-

+0100] caracteristicas/hoteles-baratos-...

+0100] baratos/destinosEstrelles/hotele...

Gc

Gc

		Web	IP	Fecha	Busqueda	Numero	origen	
	23343 w	ww.akumenius.com	66.249.76.216	[23/Feb/2014:16:17:17 +0100]	GET /destinos-caracteristicas/hoteles-baratos	200 8321	- Gc	
	23344 w	ww.akumenius.com	66.249.76.216	[23/Feb/2014:16:17:21 +0100]	GET /destinos-caracteristicas/hoteles-baratos	200 7188	- Gc	
In [62]:	# eliminamos la columna Búsqueda, y Vlog(que vemos que no aporta nada)							
	df=df.d	drop("Busqueda"	',axis=1)					
In [63]:	df=df.d	drop("VLOG",axi	.s=1)					
In [64]:	df.iloc	c[334:345]						
Ou+[6/1:		Web	ID	Focha N	lumero origen Navegador	oncion		

Out[64]:		Web	IP	Fecha	Numero	origen	Navegador	opcion	
	334	www.akumenius.com	66.249.76.216	[23/Feb/2014:03:18:21 +0100]	404 3100	-	Mozilla/5.0 (compatible, Googlebot/2.1, +http	GET	/hoteles-ba
	335	www.akumenius.com	66.249.76.216	[23/Feb/2014:03:18:23 +0100]	404 3100	-	Mozilla/5.0 (compatible, Googlebot/2.1, +http	GET	/hoteles-ba
	336	www.akumenius.com	180.76.5.200	[23/Feb/2014:03:18:24 +0100]	404 3100	-	Mozilla/5.0 (compatible, Baiduspider/2.0, +ht	GET	/hoteles-ba
	337	www.akumenius.com	66.249.76.216	[23/Feb/2014:03:18:25 +0100]	200 8814	-	Mozilla/5.0 (compatible, Googlebot/2.1, +http	GET	baratos/destir
	338	www.akumenius.com	66.249.76.216	[23/Feb/2014:03:18:26 +0100]	404 3100	-	Mozilla/5.0 (compatible, Googlebot/2.1, +http	GET	/hoteles-ba
	339	www.akumenius.com	66.249.76.216	[23/Feb/2014:03:18:28 +0100]	404 3100	-	Mozilla/5.0 (compatible, Googlebot/2.1, +http	GET	/hoteles-barat
	340	www.akumenius.com	66.249.76.216	[23/Feb/2014:03:18:30 +0100]	404 3100	-	Mozilla/5.0 (compatible, Googlebot/2.1, +http	GET	/hoteles-ba

	Web	IP	Fecha	Numero	origen	Navegador	opcion	
341	www.akumenius.com	66.249.76.216	[23/Feb/2014:03:18:33 +0100]	404 3100	-	Mozilla/5.0 (compatible, Googlebot/2.1, +http	GET	/hoteles-ba
342	www.akumenius.com	66.249.76.216	[23/Feb/2014:03:18:33 +0100]	200 8815	-	Mozilla/5.0 (compatible, Googlebot/2.1, +http	GET	baratos/destir
343	www.akumenius.com	66.249.76.216	[23/Feb/2014:03:18:35 +0100]	200 16003	-	Mozilla/5.0 (compatible, Googlebot/2.1, +http	GET	/destinc
344	www.akumenius.com	66.249.76.216	[23/Feb/2014:03:18:37 +0100]	200 8452	-	Mozilla/5.0 (compatible, Googlebot/2.1, +http	GET	/destinc